

1. Descripción general del dataset

El dataset contiene aproximadamente 10.400 registros de transacciones de un negocio retail. Incluye información de clientes, productos, fechas de compra, cantidades adquiridas, precio por unidad y gasto total por transacción. El objetivo del dataset es permitir el análisis de ventas y del comportamiento de los clientes.

2. Problemas iniciales del dataset

Tras una primera exploración del dataset mediante herramientas de Pandas, se identificaron varios problemas de calidad de datos. Se detectaron valores faltantes en las columnas relacionadas con clientes (**customer_name**, **age** y **city**), así como en **purchase_date**, **purchase_quantity** y **total_spent**.

Además, se encontraron 367 filas completamente duplicadas y algunas inconsistencias en los tipos de datos, especialmente en **purchase_date**, que se encontraba almacenada como **object** en lugar de **datetime64[ns]**.

Por último, el análisis descriptivo inicial mostró posibles valores atípicos en las variables **age**, **purchase_quantity**, **price_per_unit** y **total_spent**.

3. Procedimientos de limpieza de datos aplicados

Se eliminaron los registros duplicados completos, ya que representan copias exactas de transacciones y pueden distorsionar el análisis de ventas.

Asimismo, se eliminaron las filas en las que faltaban simultáneamente las variables **purchase_quantity** y **total_spent**, al tratarse de información esencial para la reconstrucción de la transacción, siendo estos registros irrecuperables desde el punto de vista analítico.

En cuanto a los valores faltantes en variables relacionadas con clientes (**customer_name**, **city**, **age**) y fechas de compra (**purchase_date**), se optó por mantenerlos y marcarlos como valores faltantes. En el contexto del retail, pueden existir transacciones válidas sin información completa de cliente, por lo que su eliminación podría introducir sesgos en el análisis.

Respecto a la variable **purchase_date**, se identificó inicialmente como tipo **object**, por lo que fue convertida al formato **datetime64[ns]** para permitir un correcto análisis temporal.

Finalmente, se realizó una estandarización de tipos de datos: variables numéricas como **age** y **purchase_quantity** fueron convertidas a tipo entero (**Int64**), mientras que las variables categóricas e identificadores (**customer_name**, **city**, **product_id**, **customer_id**, entre otras) fueron convertidas al tipo **string** para garantizar consistencia en el análisis.

4. Validación de calidad de datos

Se realizaron distintas comprobaciones utilizando herramientas de Pandas con el objetivo de validar la calidad del dataset tras el proceso de limpieza.

En primer lugar, mediante la función `isna().sum()` se evaluó la presencia de valores nulos por columna. Se observó la existencia de 14 valores nulos restantes, frente a los 722 detectados inicialmente. Estos registros se han mantenido como *flagged*, ya que no se consideran incompatibles con la existencia de una transacción en el contexto del retail.

A continuación, se verificó la correcta estandarización de los tipos de datos, confirmando que todas las variables fueron convertidas a sus formatos adecuados. Asimismo, se incorporaron columnas booleanas para la identificación de valores atípicos (*outliers*) y datos faltantes relevantes, así como una columna de validación (*check*) para comprobar la coherencia de las transacciones, verificando que `purchase_quantity * price_per_unit = total_spent`, sin detectarse inconsistencias tras la corrección.

Por otra parte, mediante la función `uplicated()` se confirmó la eliminación de registros duplicados, quedando el dataset libre de duplicados.

Como resultado del proceso de limpieza, el dataset final se reduce de 10.400 a 9.340 registros.

Finalmente, el análisis de outliers detectó los siguientes valores atípicos, los cuales han sido marcados para su posterior revisión:

- `outlier_age`: 14
- `outlier_purchase_quantity`: 100
- `outlier_price_per_unit`: 95
- `outlier_total_spent`: 195

Estos valores no han sido eliminados, ya que se han mantenido como flags para permitir un análisis posterior más detallado.

5. Entrega final del dataset limpio

El dataset limpio ha sido exportado en formato CSV como `cleaned_dataset.csv`, listo para su uso en análisis posteriores.